


图 1 | 蓝线是“读取还没完成”，不是 SSD 持续传输

蓝条从“发起读取”到“该层 KV 全部到达 HBM”，包含排队、服务与接收。

同一 NPU 的读取行全部空白 = 没有未完成的读取；不代表 NPU 或 SSD 空闲。


■ 蓝：层读取未完成 ■ 青：NPU 计算 ■ 红：NPU 等 I/O

A 完整 1 秒总览 · 四卡平均计算利用率 76.2261%



B NPU1 放大：分开看每一层的读取，再对照 NPU 状态

请求 100020；层号从 L0 起计。空心圆 = 发起，实心方块 = HBM 到齐。



a 26.854 ms L3 读齐、红色等待结束；开始算 L3，同时发起 L4 读取。

b 33.343 ms L4 已经到齐；NPU1 仍在算 L3，尚未发起 L5 读取。

c 39.244 ms L3 计算结束；开始算 L4，同时发起 L5 读取。

读图关键：b→c 是预取已完成的空白，不是 I/O 卡住；NPU 状态条仍为青色计算。

当前模型：开始计算 L 层才预取 L+1；跨请求预取已开启，但不是无限层深预取。