


图 4 | 分清计算时间、读取延迟与 SSD 服务时间

■ NPU0: V=1.148 MiB, C=0.582 ms ■ NPU2: V=262.797 MiB, C=29.857 ms
■ NPU1: V=263.506 MiB, C=12.390 ms ■ NPU3: V=262.797 MiB, C=29.857 ms

V = 每层读取量; C = 每层计算时间。彩色横条是计算, 非读取。


A NPU 计算与等待: 精确事件时间线

■ ■ ■ 彩色实心: 计算 灰斜纹: 等待 I/O | 短竖线: 发起读取 (非结束)




B 同一个 SSD 的时间分配 (每 0.1 ms 分桶)

色带厚度 = 该卡服务时长 ÷ 0.1 ms × 100%; 灰色 = 空闲



C 微秒放大: 8.000-8.100 ms 的真实命令顺序

块内数字为 NPU 编号; 绿/紫交替; 一条满命令约 4.196 μs



B 中蓝细条是短服务片段, 不是细线符号; 排队时间不计入 SSD 服务。

长虚线仅为周期参考线; 不是读取结束。B 的上下堆叠不表示并行服务。