


图 4A | 每张卡分开看：计算、读取发起、SSD 完成

■ NPU0: V=1.148 MiB, C=0.582 ms ■ NPU2: V=262.797 MiB, C=29.857 ms
■ NPU1: V=263.506 MiB, C=12.390 ms ■ NPU3: V=262.797 MiB, C=29.857 ms

V = 每层读取量；C = 每层计算时间。读取线包含排队，不表示连续独占 SSD。

○ 发起读取 ■ 最后 SSD 完成 ◆ HBM 到齐 (符号下移) ▨ NPU 等 I/O



测量窗口内的相对时间 (ms)；图下表给出标记的精确时刻

同页查时刻：a/b 是各卡两次相邻读取；深色示例对应下表，浅色为其余读取。

标记	请求 / 层	○ 发起 (ms)	■ SSD 完成 (ms)	◆ HBM 到齐 (ms)
0a	R111/L6	7.589134	10.128278	10.130560
0b	R111/L7	10.130560	26.878557	26.881344
1a	R100020/L3	9.387382	26.850528	26.853780
1b	R100020/L4	26.853780	33.339835	33.343087
2a	R200010/L2	7.561568	20.417279	20.420636
2b	R200010/L3	37.418131	50.273842	50.277199
3a	R300010/L2	7.557372	20.241040	20.244397
3b	R300010/L3	37.413935	50.097603	50.100960

读法：发起间隔量的是○到下一次○，不是○到■。虚点线不是 SSD 空闲。

■ 与◆通常只差 2-4 μs，符号上下错开便于辨认；横向时刻未移动，数值见表。

图边界不是读取结束；跨边界的读取照实截断。共享 SSD 实际服务请看下一页 B/C。