


NPU1 | R100020 / L3 为什么晚到？

■ NPU0: V=1.148 MiB, C=0.582 ms ■ NPU2: V=262.797 MiB, C=29.857 ms
■ NPU1: V=263.506 MiB, C=12.390 ms ■ NPU3: V=262.797 MiB, C=29.857 ms

本例：读 263.506 MiB；计算预算 12.390165 ms；自身 SSD 服务只需 6.433249 ms。

A 同一时间原点：窗口内的相对时刻（不是从 a 重新计时）



B 接收尾部放大：d→e = 3.252029 μ s (不是 ms)



标记	时刻 (ms)	事件含义
a	9.387382	开始算 L2，同时发起 L3 读取
b	20.417279	L3 的第一条命令终于开始 SSD 服务
c	21.777547	L2 算完；L3 尚未到齐，开始等待
d	26.850528	L3 的最后一条命令完成 SSD 服务
e	26.853780	L3 到齐 HBM，等待结束，开始算 L3

结论：b-a 的排队耗掉提前量；从 a 到 e 共 17.466398 ms，超过预算 5.076233 ms。