


图 5 | 0–10 ms 放大：四卡状态与 SSD 时间占比

NPU0: V=1.148 MiB, C=0.582 ms NPU2: V=262.797 MiB, C=29.857 ms
NPU1: V=263.506 MiB, C=12.390 ms NPU3: V=262.797 MiB, C=29.857 ms


V = 每层读取量；C = 计算时间。条内 Lx = 计算层；黑竖线/“读Lx” = 发起读取。

A 图 4A 的精确事件放大（不是新的利用率统计窗口）



B 同期 SSD 服务：仍按 0.1 ms 分桶，蓝条宽度放大 10 倍

5.2–5.3 ms: 蓝色 28.029% + 灰色空闲 71.971% = 100%



与 A 图相同的时间原点 (ms)
NPU0 的 L7→L0 是请求 110→111 的切换；L0 读取已由前一请求提前发起。

→ 表示该计算/等待延伸到右边界之外；10 ms 只是视窗边界，不是完成时刻。