


深预取预算 | NPU0 的“一层提前量”只有 0.582149 ms

每份 NPU0 KV=1.148071 MiB；以下仅为固定延迟下的预算估算，未实现或验证深预取。



可提供的累计计算窗口 (ms)，不表示这些层已经能够全部提前发起

2 份只能提供 1.164299 ms；29 份才超过 16.7 ms；严格覆盖 17 ms 需要 30 份。

NPU2/3 每份 KV=262.797 MiB，同样缓存 29 份要约 7.442 GiB，远大于 NPU0。

每请求仅 8 层，29 份意味着更深跨请求/跨层机制；还要求未来地址已知、HBM 容量够。

更多预取也会改变排队，所以“29”不是收益承诺，更不是当前仿真已经开启的层深。