


Ordered 局部放大：短流算完了，数据还在前方长流后面排队

真实片段 3094–3105 ms (3.094–3.105 秒) | 32 NPU / 6 SSU | Baseline, 所有 I/O 使用 Path 0



直接证据：目标短块排队的 5.809 ms 中，5.704 ms (98.2%) 是盘在服务前方长流。

该短块真正盘读仅 4.196 μ s；链路传输 3.357 μ s，链路排队为 0。不能把 5.817 ms 读取跨度当成盘服务时间。

实际服务量：长层 262.969 MiB，每盘 255 块，累计盘服务 1.070 ms/盘；短层 1.203 MiB，共 7 块，每盘累计盘服务 0.004–0.008 ms (6 盘并行)。

阻塞长块来自 NPU 0、1、2、4、5、6，全部是内部第 3 层 (L2)；本图没有长流首层 L0 读取。框内首个长块仅计其与等待区间重叠的剩余服务时间。

本图用局部解释一次等待，不代表整窗平均。原 [2,4] 秒全卡平均利用率仍为 83.60%；全程逐盘名义需求峰值 34.14 < 40 GiB/s。

读取跨度、计算与停工来自层事件；盘服务顺序来自逐块重放记录。重放的全部请求、层时间及原窗口结果与原运行完全一致。微秒服务条按真实比例绘制，箭头仅定位。

短 request=8000307 / 长示例 request=2000304 · 原结果 SHA256 da0415bed298e714 · 数据与推导: ordered_zoom_evidence.json