

11 长 / 21 短 · RR 短画像轮转：Baseline 计算与等待时间线


32 NPU / 6 SSU · 每盘 40 GiB/s · [2, 4) 秒 · 设备 U = 72.8428%

长卡 NPU 0-10 (仅 LL) | 短卡 NPU 11-31 (仅 SS)

名义最热盘峰值：全程 31.7359 / 暖窗 31.7359 GiB/s

短卡：S1 → S2 → S3 轮转至清单耗尽；长卡：固定同一长画像

长卡计算 (LL) 短卡计算 (SS) 接纳后 I/O 等待 空闲 (本窗为 0)



短 SS：1K/128、1K/256、1K/384 (外推)；长 LL：192K/768 (插值)；全局 19,456 请求。

橙色为接纳后的实际 I/O barrier 等待，排除接纳前排队；32 卡整窗 active，区间未移动或加宽。

请求 arrival 均为 0；重绑保留每条原请求的 C/V 和物理 placement；同绑定 random/RR 保持每卡人口一致。

种子 7 | 输入 e6bd9ec18d3aca6e | 仿真结果，非硬件实测