


定序混合 · Baseline: 32 卡计算与等待

32 NPU / 6 SSU · 每盘 40 GiB/s · [2, 12) 秒 · U = 97.8355%

短请求总长 32K / 48K / 64K；长请求 176K；全部直接取自 data，每请求 8 层

每卡完整队列重复 3 遍：新长输入，非旧日志拼接；仅 seed 7

短请求计算 长请求计算 接纳后 I/O 等待



按真实层事件裁剪；无时间移动或拼接。32 卡全窗有任务，橙色不含接纳前排队。

前段的等待后来显著减少：这组混合输入不能证明长期维持 10 个百分点损失。