


定序混合 · Once per layer: 32 卡计算与等待

32 NPU / 6 SSU · 每盘 40 GiB/s · [2, 4) 秒 · U = 99.2081%

短请求总长 32K / 48K / 64K；长请求 176K；全部直接取自 data，每请求 8 层

同种子 Random / Ordered 保留每卡同一批请求，只改变卡内顺序；每卡暖窗都有长短计算

短请求计算 长请求计算 接纳后 I/O 等待



按真实层事件裁剪；无时间移动或拼接。32 卡全窗有任务，橙色不含接纳前排队。

全程最热盘名义需求 39.925564 < 40 GiB/s；窗口 SLO×1.5 = 100.00% (接纳后代理)。