


原始画像的真实 FIFO 局部：长读排在前，短卡算完后仍需等数据

32 NPU / 6 SSU · ordered Baseline · seed 7 · 短 32K / 1024, 长 176K / 1024 · 全部 C / V 来自 data

短卡：读取 18.784 ms – 计算 7.257 ms = 停工 11.527 ms；长卡：读取 19.353 ms < 计算 31.416 ms



直接证据：目标块盘排队的 18.123 ms 中，17.955 ms (99.07%) 在服务排在前面的 Long 块；盘无空闲间隙。

这些先驱长块全是 “Long → Long” 的跨请求 L0 预取；正在计算的请求 6000007 与预取中的请求 6000008 不同。

下一条 Long 的首层由上一条 Long 的末层计算掩盖；不是短 → 长切换造成计算预算骤减。短卡的等待则超过了自己的计算预算。

下两行分别表示目标块经历的阶段和该盘实际服务顺序；空白处未展开，不代表盘空闲。读取跨度包含排队、盘读与链路，不能当连续占盘。

局部最大短等待示例，不代表平均；原 [2,4)s 设备 U = 89.5726%。名义 V/C 不额外叠加下一请求 L0，也不等于实际吞吐。