


随机顺序 · Once per layer: 六盘名义需求

32 NPU / 6 SSU · 每盘 40 GiB/s · [2, 4) 秒 · U = 99.9361%

短请求总长 32K / 48K / 64K; 长请求 176K; 全部直接取自 data, 每请求 8 层

同种子 Random / Ordered 保留每卡同一批请求, 只改变卡内顺序; 每卡暖窗都有长短计算



全程逐事件峰值 39.199692 GiB/s; 本窗口峰值 39.199692 GiB/s。

需求 = 当前已接纳请求逐盘 D/C; 沿用原约定, 下一请求首层预取不另加。此图不是实际吞吐。

seed 7 · 输入指纹 f606ad5ca420e199 · 原始仿真日志离线重绘; 非真实硬件测量