


# NPU 5：带宽诉求参考、SSD服务与NPU交付

定序输入 · 32 NPU / 6 SSU · 每盘40 GiB/s · NPU链路50 GiB/s · seed7 · [3.2,4)秒

绿/蓝线按真实服务片段积分取0.5ms均值，红线是名义参考；两策略共用纵轴，不裁切服务峰值。



红线仅为当前已接纳请求的每层D/C参考，不能沿请求寿命积分当作实际所需字节；下一请求L0仍真实执行。

绿线汇总六盘归属于本NPU的实际服务，不是一块盘的带宽；蓝线计链路传输交付，不是进入链路队列的到达量。

橙色严格按层日志等待区间绘制。两策略同卡同绝对窗可能处理不同请求；图中U是0.8秒局部窗，不是58秒均值。