

原始画像桥接输入（12秒试验） · Baseline：长时间计算与等待

32 NPU / 6 SSU · 每盘 40 GiB/s · [2, 12) 秒 · 平均利用率 90.7086%

短请求总输入 32K / 48K / 64K；长请求 176K；每请求 8 层

真实仿真时序；队列按各卡完成进度推进，未移动、拼接时间或插入同步屏障

短请求计算 长请求计算 接纳后 I/O 等待



全部 32 卡全窗有任务；橙色为已接纳任务等待 I/O，不含到达后等待接纳。

每卡两类都有计算：True；任一卡任一类最低计算占比 12.33%；最少切换 8 次。

C 与读取量取自原始 data；人工安排请求序列。逐盘名义 D/C 不另加下一请求首层预取。

seed 7 · 输入指纹 056c88e478bc61f8 · 数值为该次运行；非真实硬件测量