


正式长窗的后半段：短请求 → 低读取量的桥接请求 → 下一个长请求

Baseline · 32 NPU / 6 SSU · 每盘40 GiB/s · seed7 · 共用绝对时间轴 [51100, 51520) ms

短请求 64K/1024：层C=12.626ms；桥接请求 32K/4096：28.593ms；长请求 176K/1024：31.416ms



长请求 L0：释放 51446.523 → ready 51462.018ms；读取生命周期 15.495ms < 前驱桥接预算 28.593ms。

NPU21 短请求32K/1024：读取生命周期 15.643ms > 本层预算 7.257ms；暴露等待 8.386ms。

淡色条是该层从释放到所有块到达NPU的时间，包含排队与传输；不是SSD独占服务或盘busy时间。

两张卡均画真实、连续的同一时间窗。等待例子取本窗后16卡最大内部层等待；不认定某一长请求为其FIFO队头。

本图来自完整60秒主案例的Baseline日志；选取50–60秒内第一次桥接，不重放、不拼接时间。