


定序混合输入 (seed 7) · Once per layer: 计算与读取等待

32 NPU / 6 SSU · 每盘40 GiB/s · [2, 12)秒 · 平均利用率 99.9674%

短请求: 32/48/64K、NQL1024; 桥接请求: 32K、NQL4096; 长请求: 176K、NQL1024

原始data画像, 每请求8层; 桥接层C=28.593ms, 单独计色; 全部真实计算均计入利用率

短请求 桥接请求 长请求 接纳后 I/O 等待



全部32卡全窗有任务; 橙色为接纳后的真实I/O等待, 不含排队等接纳, 也不含耗尽后的空闲。

每卡均有短请求与长请求的计算; 最低短请求计算占比 5.05%, 最低长请求计算占比 7.54%。

每卡至少 6 次长/短角色切换; 输入序列人工安排, 无运行时同步屏障; 下一请求L0预取仍完整执行。

seed 7 · 输入指纹 a69b0036b4e6a935 · 图为完整日志真实区间; 非硬件测量