

定序混合输入 (seed 7) · Once per layer: 计算与读取等待

32 NPU / 6 SSU · 每盘40 GiB/s · [2, 60)秒 · 平均利用率 99.9611%

短请求: 32/48/64K、NQL1024; 桥接请求: 32K、NQL4096; 长请求: 176K、NQL1024

原始data画像, 每请求8层; 桥接层C=28.593ms, 单独计色; 全部真实计算均计入利用率

短请求 桥接请求 长请求 接纳后 I/O 等待

