

Baseline Random: 32 张 NPU 的计算与 I/O 等待

32 NPU / 3 SSU × 40 GiB/s · [2, 4) 秒 · NPU 平均利用率 87.83%

A: 128K 总长 / 新增 256; B: 32K 总长 / 新增 4K; 每卡请求数 A:B=1:2

A 请求计算 B 请求计算 I/O 等待



全窗有任务: 32/32 卡; 本窗实际计算过 A 和 B: 32/32 卡。每请求 8 层, 全部计算计入利用率。

橙色为接纳后等待读取; 不含到达后等待接纳。图为完整仿真的真实时间区间。