




Baseline Ordered · 3 SSU · NPU 25：为什么发生等待

A：128K 总长 / 新增 256；B：32K 总长 / 新增 4K；每卡请求数 A:B=1:2

目标 B 请求 L0：预算 6.024 ms；读取 38.500 MiB；等待 37.040 ms



每盘物理服务速度 40 GiB/s；读取后还经过 NPU 的 50 GiB/s 接收链路，最后一块到达后才能继续计算。