


Baseline Ordered · 4 SSU · NPU 15：为什么发生等待


A: 128K 总长 / 新增 256; B: 32K 总长 / 新增 4K; 每卡请求数 A:B=1:2

目标 B 请求 L0: 预算 6.024 ms; 读取 38.500 MiB; 等待 25.605 ms


NPU 15 的计算与等待（边缘区间可能被裁剪）



本卡各层：圆点为读取释放/到齐，黑竖线为计算截止；线段包含排队，不是 SSD 持续服务



各盘真正服务的 IO 块：白色为空闲；粉色为目标层；其余颜色含其他 NPU 的请求



每盘物理服务速度 40 GiB/s; 读取后还经过 NPU 的 50 GiB/s 接收链路，最后一块到达后才能继续计算。