


32 NPU / 3 SSU × 40 GiB/s · [2, 20) 秒 · NPU 平均利用率 64.22%

A: 128K 总长 / 新增 256; B: 32K 总长 / 新增 4K; 每卡请求数 A:B=1:2

■ A 请求计算    ■ B 请求计算    ■ I/O 等待



全窗有任务：32/32 卡；本窗实际计算过 A 和 B：32/32 卡。每请求 8 层，全部计算计入利用率。

橙色为接纳后等待读取；不含到达后等待接纳。图为完整仿真的真实时间区间。