


Baseline Ordered · 3 SSU · NPU 25：为什么发生等待


A：128K 总长 / 新增 256；B：32K 总长 / 新增 4K；每卡请求数 A:B=1:2

目标 B 请求 L0：预算 6.024 ms；读取 38.500 MiB；等待 37.040 ms


NPU 25 的计算与等待（边缘区间可能被裁剪）



本卡各层：圆点为读取释放/到齐，黑竖线为计算截止；线段包含排队，不是 SSD 持续服务



各盘真正服务的 IO 块：白色为空闲；粉色为目标层；其余颜色含其他 NPU 的请求



每盘物理服务速度 40 GiB/s；读取后还经过 NPU 的 50 GiB/s 接收链路，最后一块到达后才能继续计算。