


NPU 20：带宽需求与实际获得的服务

32 NPU / 3 SSU × 40 GiB/s · 每 0.5 ms 按真实服务时间积分

A: 128K 总长 / 新增 256; B: 32K 总长 / 新增 4K; 每卡请求数 A:B=1:2



名义需求是当前请求的 V/C 参考值；等待期间仍显示它，但其积分不是新增读取量。

等待源于数据没有在截止前到齐；等待时实际带宽也可能高于参考值。请结合累计字节图判断。