




Baseline Ordered · 6 SSU · NPU 28：为什么发生等待

A: 128K 总长 / 新增 256; B: 32K 总长 / 新增 4K; 每卡请求数 A:B=1:2

目标 B 请求 L0: 预算 6.024 ms; 读取 38.500 MiB; 等待 14.167 ms



每盘物理服务速度 40 GiB/s; 读取后还经过 NPU 的 50 GiB/s 接收链路，最后一块到达后才能继续计算。