


Once per layer Random: 32 张 NPU 的总带宽需求与供给

32 NPU / 3 SSU × 40 GiB/s · seed 7 · warm [2,4) 秒 · NPU 平均利用率 91.24%

整个窗口的时间平均：需求 188.888 GiB/s；实际供给 111.674 GiB/s



供给先按每张卡各自的层周期取平均（包含等待），再对 32 卡相加。

跨请求周期也计入；窗口两端只用窗内实际收到的字节和片段时长，因此曲线面积与整窗收到量一致。

蓝线表示周期平均供给；总需求是 32 卡 V/C 参考值之和。两条线之比不能作为 NPU 利用率。