


流量分配策略 Ordered: 32 张 NPU 的每层平均带宽与需求

32 NPU / 3 SSU × 40 GiB/s · seed 7 · warm [2,4] 秒 · 整机 U=83.42% · 平均每卡需求=7.944、供给=3.269 GiB/s

B_i: 当前请求每层 V/C 平均 b_i: 每个完整内部层周期一个值 灰区: 跨请求 / 窗口截断; 蓝线不填值

每行一张卡; 左侧 U 和右侧带宽均统计完整 warm [2,4] 秒。蓝线仍按各自层周期取均值。

整窗平均 (GiB/s)



时间 (秒)