

混合请求下的 QoS 策略对比

32 NPU / 8 SSU ，单盘 40 GiB/s ，状态采集周期 5 ms ；每张卡输入多种请求

策略	主要能力	外推短流混合 • E72		原始参数混合 • V38	
		利用率 %	SLO 达标 %	利用率 %	SLO 达标 %
固定单路 Baseline / fixed	每盘读取固定进入 Path0	80.29	82.73	96.23	83.29
压力感知选路 Once / fixed	根据 QoS Path 的 I/O 压力为每一层选择路径	90.68	99.04	96.36	91.24
预留感知选路 New Once / fixed	在 Once 基础上，计入全局已安排但未完成的 I/O	91.62	99.68	97.68	96.06
全局客户端调度 策略 1 / pipeline	选择 NPU ，并控制 I/O 下发时机	93.48	99.80	95.68	96.60
盘内协同调度 策略 2 / pipeline	增加盘内 I/O 调度 保留原生 QoS 约束	92.85	99.79	95.09	97.08
跨盘协同调度 策略 3 / pipeline	结合各盘同层读取进度 协调 I/O 优先级	93.98	99.79	94.94	97.18
跨盘协同，固定分卡 策略 3 / fixed	保留输入的 NPU 绑定 使用策略 3 的 I/O 调度	90.17	99.69	97.83	94.77

整机利用率高，仍可能有短请求等待；选路、选卡与整批完成时间需要分别评价。

注：利用率取 [1,2] 秒内 32 卡平均； SLO 覆盖完整输入，接纳至 8 层完成 $\leq 1.5 \times$ 纯计算时间，不含接纳前排队。
seed7 ； E72 共 18,624 条， V38 共 2,944 条。粗体为列内显示最高值。 E72 含 1K 外推； V38 画像参数来自 data 。

输入一：整机利用率约 96% 的请求混合

V38 ， 32 NPU / 8 SSU ； 每卡 92 条，全局 2,944 条；各卡配额相同、完整顺序独立

Baseline U1/U2 ： 96.23% / 96.66% New Once ： 97.68% / 97.42%

最热盘平均 ρ ： 97.30%

序列长度 / NQL • 类别	每层 C (ms)	每层读取 (MiB)	每卡条数	请求数量占比	纯计算时间占比
32K / 128 • SS	1.178	43.828	28	30.43%	4.32%
48K / 256 • SS	2.669	65.656	28	30.43%	9.79%
64K / 512 • SL	6.386	87.312	28	30.43%	23.43%
192K / 1024 • LL	34.101	262.625	2	2.17%	8.94%
192K / 2048 • LL	68.056	261.250	6	6.52%	53.51%

每卡 28+28+28 条较短请求、 2+6 条长请求； 192K 两类合计占 62.45% 的纯计算时间。

完整输入的纯计算时间构成



K=1024 token ； NQL 为本次新增 query token 数。 C 为每层纯计算时间；读取量为 SSD→HBM 的跨盘合计。
每请求 8 层、 batch=1 ； 所有请求 t=0 到达。 五种画像均取原 data ； 无 C 缩放、无尾块补齐。

输入二：整机利用率约 80% 的请求混合

E72 ， 32 NPU / 8 SSU ； 每卡 582 条，全局 18,624 条；各卡配额相同、完整顺序独立


Baseline U1/U2 ： 80.29% / 82.72% New Once ： 91.62% / 93.80%

最热盘平均 ρ ： 93.54%

序列长度 / NQL • 类别	每层 C (ms)	每层读取 (MiB)	每卡条数	请求数量占比	纯计算时间占比
1K / 128 • SS	0.528	1.203	188	32.30%	17.84%
1K / 256 • SS	0.697	1.031	188	32.30%	23.57%
1K / 384 • SS	0.899	0.859	188	32.30%	30.40%
192K / 256 • LS	8.708	263.656	18	3.09%	28.18%

每卡 188+188+188 条低读取量短请求、 18 条大读取请求；三短画像占 71.82% 的纯计算时间。

完整输入的纯计算时间构成



K=1024 token ； NQL 为本次新增 query token 数。 C 为每层纯计算时间；读取量为 SSD→HBM 的跨盘合计。
每请求 8 层、 batch=1 ；所有请求 t=0 到达。三个 1K 画像使用外推， NQL384 还含插值； 192K 画像取原 data ，无 C 缩放。

32 NPU / 6 SSU：较低利用率对应什么输入

两组不同请求配额；每组都在自己的冻结输入上比较 Baseline 与 New Once ， seed7

A：三种外推短流 + 一种长流

Baseline U1/U2： 74.53% / 80.11%

New Once U1/U2： 91.89% / 97.61%

序列长度 / NQL	每卡条数	C 时间占比
1K / 128	195	19.84%
1K / 256	195	26.21%
1K / 384	195	33.81%
192K / 256	12	20.14%

每卡 597 条；全局 19,104 条

最热盘平均 p 95.20% ；短组 C 占比 79.86%

B：三种原始参数短流 + 两种长流

Baseline U1/U2： 95.72% / 96.25%

New Once U1/U2： 98.41% / 96.68%

序列长度 / NQL	每卡条数	C 时间占比
32K / 128	18	2.36%
48K / 256	18	5.34%
64K / 512	18	12.79%
192K / 1024	3	11.38%
192K / 2048	9	68.13%

每卡 66 条；全局 2,112 条

最热盘平均 p 96.88% ；短组 C 占比 20.49%


A 的短请求占据更多计算时间， Baseline 整体损失更明显； B 仍需逐类查看短请求等待。

U1=[1,2] 秒， U2=[2,3] 秒；全部 32 卡全窗 active 。每盘 40GiB/s 、每卡接收 50GiB/s ；平均 p 不保证层期限可满足。

A 对应 8 盘 E80 的同人口对照，区别于前页 E72 。 B 在 8 盘 V38 基础上重新配额；两者都无 C 缩放。

每张 NPU 究竟收到什么顺序的请求？

V38：每张卡 92 条，下图绘制全部 2,944 条输入请求；每格等宽表示一条请求的位置



相同配额，各卡独立乱序；相同画像会多次出现，但没有重复固定的小循环。

完整列表一次 shuffle：Random(seed + NPU 编号 × 100003)，本页 seed=7；32 条完整顺序各不相同。

这是输入位置图，各格的实际计算时长不同。所有请求 t=0 入队，固定分卡策略按各卡序列执行。

S1-S3 pipeline 还会重新分配 NPU。完整原始输入和逐条顺序 CSV 随报告保存；频率与到达并非生产 trace。

96% 的整机平均，掩盖了哪些请求？

相同 V38 种子 7：整机 U 取 [1,2] 秒；下表逐类指标覆盖同一批完整请求，保留长流和变差的画像

逐类计算占比 = 该类纯计算总时间 / 该类接纳至完成总历时

序列长度 / NQL · 类别	C 时间权重	Baseline 计算占比	New Once 计算占比	Baseline SLO	New Once SLO
32K / 128 · SS	4.32%	57.80%	92.45%	483/896	870/896
48K / 256 · SS	9.79%	86.93%	99.49%	817/896	894/896
64K / 512 · SL	23.43%	98.26%	86.53%	896/896	808/896
192K / 1024 · LL	8.94%	98.81%	97.62%	64/64	64/64
192K / 2048 · LL	53.51%	99.51%	99.17%	192/192	192/192

192K 两类占 62.45% 的纯计算时间；最短 32K/128 仅占 4.32% ，其等待容易被整体平均掩盖。

New Once 更好地保护前两类，但 64K/512 和长类的计算占比下降；不能概括为所有请求都更快。

SLO：接纳至完成 ≤ 1.5 × 自身 8 层纯计算时间；不含接纳前排队。64K/NQL512 属于 SL ，短组并非全属 SS。

另一组三种严格 SS 的两种子复核也发现等待，详见完整研究报告；本页不把不同人口的结果混合平均。