

32 NPU ： 混合输入下的策略利用率

SSU 盘数明确分列；单盘 40 GiB/s ， 状态采集周期 5 ms ；表中数值为 NPU 利用率（ % ）

策略	主要能力	1K 短请求 + 192K 大读取请求		32K / 48K / 64K + 192K 请求	
		6 盘 SSU • 597 条 / 卡	8 盘 SSU • 582 条 / 卡	6 盘 SSU • 66 条 / 卡	8 盘 SSU • 92 条 / 卡
Baseline • 固定分卡	每盘固定使用 Path0	74.53	80.29	95.72	96.23
Once • 固定分卡	按路径 I/O 压力选路	—	90.68	—	96.36
New Once • 固定分卡	选路计入全局未完成 I/O	91.89	91.62	98.41	97.68
策略 1 • 可重分 NPU	全局选卡、控制 I/O 下发	—	93.48	—	95.68
策略 2 • 可重分 NPU	增加盘内 I/O 调度	—	92.85	—	95.09
策略 3 • 可重分 NPU	跨盘协调同层 I/O 优先级	—	93.98	—	94.94
策略 3 • 固定分卡	保留输入绑定，跨盘调度	—	90.17	—	97.83

每张 NPU 的具体输入（序列长度 / NQL × 条数； K = 1024 token ）

6 盘： 1K/128 、 1K/256 、 1K/384 各 195 条； 192K/256 有 12 条。	6 盘： 32K/128 、 48K/256 、 64K/512 各 18 条； 192K/1024 有 3 条， 192K/2048 有 9 条。
8 盘： 1K/128 、 1K/256 、 1K/384 各 188 条； 192K/256 有 18 条。	8 盘： 32K/128 、 48K/256 、 64K/512 各 28 条； 192K/1024 有 2 条， 192K/2048 有 6 条。

利用率： seed7 ， [1,2] 秒内 32 卡平均；粗体为该列已测最高值；一为未测试。 6 盘与 8 盘配额不同，不能只归因于盘数。

各卡配额相同、完整顺序独立打乱；全部 t=0 到达，每请求 8 层、 batch=1 。 1K 参数外推（ NQL384 含插值）；右组参数取原 data 。

NQL 为本次新增 query token 数。右组 8 盘中， 192K 两类占 62.45% 的纯计算时间，整机 96.23% 仍可能掩盖短请求等待。