

QoS 调度策略对比

32 NPU ，单盘 40 GiB/s ，状态采集周期 5 ms

策略	主要能力	5 SSU		6 SSU		7 SSU	
		利用率 %	SLO 达标 %	利用率 %	SLO 达标 %	利用率 %	SLO 达标 %
固定单路 Baseline	每盘读取固定进入 Path0	87.41	62.93	95.99	79.05	98.79	87.29
压力感知选路 Once per layer	每层查看 QoS Path 的 I/O 压力 动态选择路径	87.57	80.75	95.98	94.46	99.41	97.59
预留感知选路 New Once	在 Once 基础上，计入全局 已安排但未完成的 I/O	87.64	78.98	96.84	94.89	99.49	97.51
全局客户端调度 策略 1	在新 Once 基础上，选择 NPU 并控制 I/O 下发时机	85.07	92.05	97.93	98.44	99.63	99.29
盘内协同调度 策略 2	在策略 1 基础上，增加盘内 I/O 调度 保留原生 QoS 约束	84.67	91.48	97.67	98.30	99.76	99.22
跨盘协同调度 策略 3	在策略 2 基础上，结合各盘读取进度 协调同一层 I/O 的优先级	84.60	92.54	98.41	98.15	99.69	99.29

策略 1–3 的接纳后 SLO 达标率提高，但整批请求完成时间均长于 Once 。

注：利用率取 [1,2] 秒内 32 卡平均；SLO 按接纳至 8 层完成 $\leq 1.5 \times$ 纯计算总时间统计，不含接纳前排队。
两次实验汇总，每次 704 请求；静态 CIR ，控制开销未计入。粗体为列内最高值。盘内及跨盘调度需要盘侧配合。