


TTFT CDF：按SLO倍数比较


8 NPU | 1 SSU × 40 GB/s | ring hash | seed 7, 19, 43

— Baseline FIFO - - - Once


组合1 $x=6.43, y=12.00$
A 200K/3564 | B 32K/1455




组合2 $x=8.69, y=12.00$
A 200K/2645 | B 24K/1325




组合3 $x=10.53, y=12.00$
A 200K/2189 | B 20K/1236



组合4 $x=13.31, y=12.00$
A 200K/1735 | B 16K/1122



组合5 $x=13.28, y=14.16$
A 200K/2048 | B 16K/1122



SLO × 1.5 达标率 (%)

组合	FIFO	Once
1	100.00	100.00
2	100.00	100.00
3	99.10	100.00
4	93.43	99.68
5	95.89	99.73


基准SLO = 各请求自身的总计算时间；竖线为SLO × 1.5。
每组汇总三个种子的全部相同请求，包含冷启动；CDF未做平滑。

组合1：TTFT / 基准SLO


A请求 200K/3564 | B请求 32K/1455

8 NPU | 1 SSU | ring hash | seed 7, 19, 43


全部请求 | 每策略 n=1248



A请求 | 每策略 n=96



B请求 | 每策略 n=1152






横轴1.5x处的CDF = TTFT $\leq$ 1.5 $\times$ 基准SLO 的请求比例。
基准SLO为该请求总计算时间；TTFT不含接纳前排队，包含冷启动。

组合2：TTFT / 基准SLO

A请求 200K/2645 | B请求 24K/1325

8 NPU | 1 SSU | ring hash | seed 7, 19, 43




横轴1.5x处的CDF = TTFT $\leq$ 1.5 $\times$ 基准SLO 的请求比例。
基准SLO为该请求总计算时间；TTFT不含接纳前排队，包含冷启动。

组合3：TTFT / 基准SLO


A请求 200K/2189 | B请求 20K/1236

8 NPU | 1 SSU | ring hash | seed 7, 19, 43


全部请求 | 每策略 n=1560



A请求 | 每策略 n=120



B请求 | 每策略 n=1440




横轴1.5x处的CDF = TTFT $\leq$ 1.5 $\times$ 基准SLO 的请求比例。
基准SLO为该请求总计算时间；TTFT不含接纳前排队，包含冷启动。

组合4：TTFT / 基准SLO


A请求 200K/1735 | B请求 16K/1122

8 NPU | 1 SSU | ring hash | seed 7, 19, 43


全部请求 | 每策略 n=1872



A请求 | 每策略 n=144



B请求 | 每策略 n=1728




横轴1.5x处的CDF = TTFT $\leq$ 1.5 $\times$ 基准SLO 的请求比例。
基准SLO为该请求总计算时间；TTFT不含接纳前排队，包含冷启动。

组合5：TTFT / 基准SLO


A请求 200K/2048 | B请求 16K/1122

8 NPU | 1 SSU | ring hash | seed 7, 19, 43


全部请求 | 每策略 n=1872



A请求 | 每策略 n=144



B请求 | 每策略 n=1728



横轴1.5x处的CDF = TTFT $\leq$ 1.5 $\times$ 基准SLO 的请求比例。
基准SLO为该请求总计算时间；TTFT不含接纳前排队，包含冷启动。